Exercices d'entraînement

Apprendre le SQL pas à pas sur une base de données de santé

Master 1 Informatique médicale — TP d'initiation au SQL — Base Eunomia GiBleed (format OMOP)

> **Comment utiliser ce document**
>
> Les exercices sont classés par difficulté croissante, en cinq niveaux. Chaque niveau commence par un mini-cours et un exemple commenté : lisez-les avant de vous lancer.
>
> Durée prévue : environ 2 heures pour les niveaux 1 à 4. Le niveau 5 est un bonus pour celles et ceux qui ont terminé.
>
> Faites les exercices dans l'ordre : chacun réutilise ce qui a été vu avant. Si vous bloquez, relisez le mini-cours et l'exemple du niveau, consultez l'aide-mémoire, puis demandez de l'aide.
>
> Copiez chaque requête qui fonctionne dans un fichier texte, avec le numéro de l'exercice. Se tromper fait partie de l'apprentissage : lisez les messages d'erreur, ils indiquent souvent où chercher.

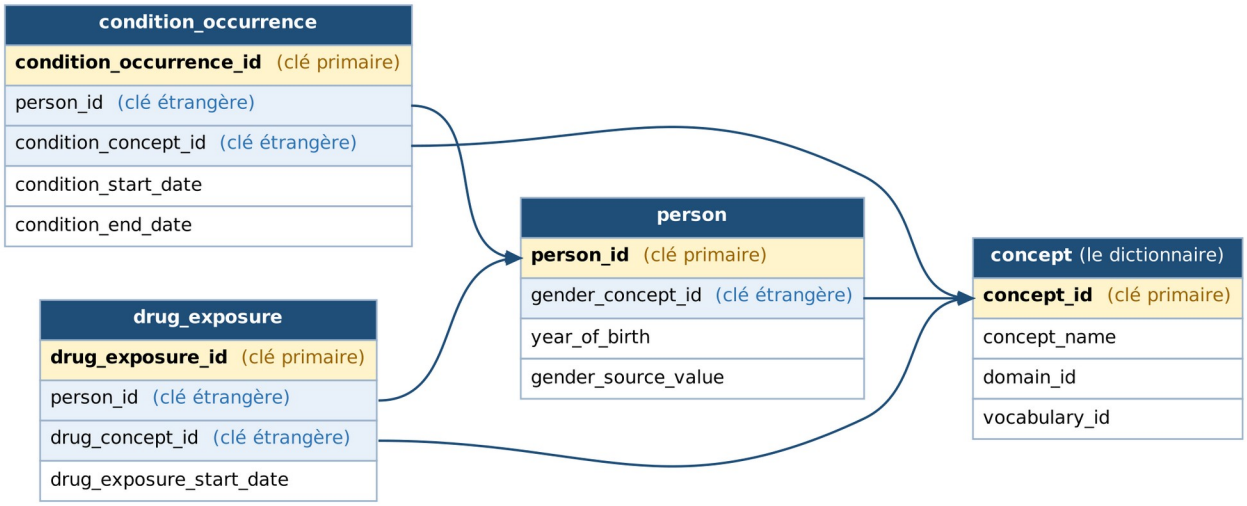
L'essentiel avant de commencer

Le vocabulaire

Mot	Ce qu'il veut dire	Exemple dans notre base
Base de données	Un ensemble de tables reliées entre elles, rangées dans un même fichier.	Le fichier eunomia_gibleed.sqlite
Table	Un tableau qui regroupe un type d'information, comme une feuille de tableur.	La table person (les patients)
Ligne (ou enregistrement)	Un élément de la table.	Un patient dans person, un diagnostic dans condition_occurrence
Colonne	Une information sur chaque ligne. Chaque colonne a un nom.	year_of_birth (année de naissance)
Requête	Une question posée à la base, écrite en langage SQL. La réponse est un tableau.	SELECT COUNT(*) FROM person;
Clé primaire	Colonne qui identifie chaque ligne de façon unique : jamais deux fois la même valeur, jamais vide.	person_id dans person
Clé étrangère	Colonne qui contient la clé primaire d'une autre table : elle crée le lien entre deux tables.	person_id dans condition_occurrence désigne un patient de person
NULL	Case vide : valeur absente ou inconnue. Ce n'est ni zéro, ni un texte vide.	Un diagnostic sans date de fin
concept_id	Dans OMOP, code numérique qui représente une information médicale. Son libellé est dans la table concept.	192671 = Gastrointestinal hemorrhage

Les tables de la base et leurs liens

Voici les tables utilisées dans ce TP. Chaque table a une clé primaire (en jaune). Les flèches partent d'une clé étrangère (en bleu) et pointent vers la clé primaire qu'elle désigne : c'est par ces liens qu'on relie les tables entre elles au niveau 3.



Aide-mémoire SQL

Je veux…	J'écris…
choisir des colonnes	`SELECT col1, col2 FROM table;`
toutes les colonnes	`SELECT * FROM table;`
filtrer des lignes	`WHERE col = 'texte' AND col2 > 10`
rechercher un mot dans un texte	`WHERE col LIKE '%mot%'`
tester une case vide	`WHERE col IS NULL`
tester une liste de valeurs	`WHERE col IN (1, 2, 3)`
trier (décroissant)	`ORDER BY col DESC`
limiter le nombre de lignes	`LIMIT 10`
supprimer les doublons	`SELECT DISTINCT col`
compter	`COUNT(*), COUNT(DISTINCT col)`
minimum, maximum, moyenne	`MIN(col), MAX(col), AVG(col)`
regrouper	`GROUP BY col`
filtrer des groupes	`HAVING COUNT(*) > 5`
relier deux tables	`FROM t1 a JOIN t2 b ON b.id = a.id`
renommer une colonne	`COUNT(*) AS nb`
extraire l'année d'une date	`strftime('%Y', col_date)`
durée en jours entre deux dates	`julianday(date2) - julianday(date1)`

> **Trois règles d'écriture**
>
> 1. Les clauses s'écrivent toujours dans cet ordre : `SELECT … FROM … JOIN … WHERE … GROUP BY … HAVING … ORDER BY … LIMIT`.
>
> 2. Les textes s'écrivent entre apostrophes droites : `'F'`. Les nombres s'écrivent sans apostrophes : `1950`.
>
> 3. Une requête se termine par un point-virgule. Les majuscules aux mots-clés (SELECT, FROM…) sont une convention de lisibilité : `select` fonctionne aussi.

Niveau 1 — Lire une table

Durée conseillée : 20 min **Notions :** SELECT, FROM, WHERE, AND, ORDER BY, LIMIT, DISTINCT, LIKE

> **Mini-cours**
>
> Une requête SQL est une question posée à la base. Elle se lit presque comme une phrase en anglais : « sélectionne (`SELECT`) telles colonnes, depuis (`FROM`) telle table, là où (`WHERE`) telle condition est vraie ».
>
> On ajoute ensuite, si besoin, l'ordre d'affichage (`ORDER BY`) et le nombre maximum de lignes à afficher (`LIMIT`).

Exemple commenté

```
SELECT person_id, year_of_birth
FROM person
WHERE gender_source_value = 'M'
ORDER BY year_of_birth
LIMIT 3;
```

Ligne de la requête	Ce qu'elle veut dire
`SELECT person_id, year_of_birth`	je veux voir deux colonnes : l'identifiant et l'année de naissance ;
`FROM person`	elles se trouvent dans la table des patients ;
`WHERE gender_source_value = 'M'`	je ne garde que les hommes (le texte 'M' s'écrit entre apostrophes) ;
`ORDER BY year_of_birth`	je trie du plus ancien au plus récent (ajouter DESC pour l'ordre inverse) ;
`LIMIT 3;`	je n'affiche que les 3 premières lignes. Le point-virgule termine la requête.

Résultat obtenu :

person_id	year_of_birth
842	1909
4722	1909
4739	1909

3 lignes.

Exercices

Exercice 1.1 — Premier contact

Affichez toutes les colonnes des 5 premières lignes de la table `person`.

Exercice 1.2 — Choisir ses colonnes

Affichez uniquement l'identifiant (`person_id`), l'année de naissance (`year_of_birth`) et le genre (`gender_source_value`) de 10 patients.

Exercice 1.3 — Filtrer avec WHERE

Affichez l'identifiant et l'année de naissance des patients nés avant 1920. Combien sont-ils ?

Exercice 1.4 — Combiner des conditions et trier

Affichez l'identifiant et l'année de naissance des femmes nées en 1980 ou après, de la plus jeune à la plus âgée.

Exercice 1.5 — Les doyens

Affichez les 5 patients les plus âgés de la base, avec leur date de naissance complète (année, mois, jour).

Exercice 1.6 — Valeurs distinctes

La table `concept` est le dictionnaire de la base : chaque code médical y occupe une ligne, et la colonne `domain_id` indique à quel domaine il appartient (médicament, diagnostic…). Quelles sont les différentes valeurs possibles de la colonne `domain_id` ?

Exercice 1.7 — Chercher dans le dictionnaire

Toujours dans la table `concept`, affichez le `concept_id`, le `concept_name` et le `domain_id` de tous les concepts dont le nom contient le mot « Ibuprofen ».

Niveau 2 — Compter et résumer

Durée conseillée : 30 min **Notions :** COUNT, COUNT(DISTINCT), IS NULL, MIN, MAX, AVG, ROUND, AS, GROUP BY, HAVING

Mini-cours

Jusqu'ici, chaque ligne du résultat correspondait à une ligne de la table. Les fonctions d'agrégation résument au contraire plusieurs lignes en une seule valeur : `COUNT(*)` compte les lignes, `MIN` et `MAX` donnent la plus petite et la plus grande valeur, `AVG` la moyenne.

`GROUP BY` fait ce calcul séparément pour chaque groupe. Par exemple, `GROUP BY gender_source_value` produit une ligne pour les femmes et une ligne pour les hommes. `AS` donne un nom lisible à une colonne calculée.

Une case vide s'appelle `NULL` (valeur absente). On la teste avec `IS NULL`, jamais avec `= NULL`.

Exemple commenté

```
SELECT gender_source_value, COUNT(*) AS nb_patients
FROM person
GROUP BY gender_source_value;
```

Ligne de la requête	Ce qu'elle veut dire
`SELECT gender_source_value, COUNT(*) AS nb_patients`	pour chaque genre, je veux le nombre de lignes, dans une colonne nommée nb_patients ;
`FROM person`	dans la table des patients ;
`GROUP BY gender_source_value;`	je forme un groupe par valeur de genre, puis je compte dans chaque groupe.

Résultat obtenu :

gender_source_value	nb_patients
F	1373
M	1321

2 lignes.

Exercices

Exercice 2.1 — Compter des lignes

Combien de lignes contient la table `condition_occurrence` (une ligne = un diagnostic) ? Et la table `person` ?

Exercice 2.2 — Clé primaire et doublons

Une clé primaire identifie chaque ligne de façon unique : elle ne peut pas contenir deux fois la même valeur.

a) Dans la table `person`, comparez le nombre de lignes et le nombre de valeurs différentes de `person_id`.

b) Faites la même comparaison dans `condition_occurrence`.

c) Que pouvez-vous en conclure sur le rôle de `person_id` dans chacune des deux tables ?

Exercice 2.3 — Les valeurs manquantes

Combien de diagnostics n'ont pas de date de fin renseignée (colonne `condition_end_date` vide) ?

Exercice 2.4 — Statistiques simples

Calculez l'année de naissance la plus ancienne, la plus récente, et l'année de naissance moyenne arrondie à l'unité. Donnez des noms lisibles aux colonnes du résultat.

Exercice 2.5 — Regrouper avec GROUP BY

Combien la table `concept` contient-elle de concepts pour chaque domaine (`domain_id`) ? Triez du domaine le plus nombreux au moins nombreux.

Exercice 2.6 — Les patients les plus suivis

Quels sont les 5 patients qui ont le plus de diagnostics enregistrés ? Affichez leur identifiant et leur nombre de diagnostics.

Exercice 2.7 — Filtrer des groupes avec HAVING

Listez les patients ayant au moins 50 diagnostics. Combien sont-ils ?

Niveau 3 — Relier les tables : les jointures

Durée conseillée : 30 min **Notions :** JOIN … ON, alias de tables, clé primaire et clé étrangère

Mini-cours

Dans OMOP, un diagnostic n'est pas écrit en toutes lettres dans condition_occurrence : on y trouve un code, `condition_concept_id`. Le libellé correspondant est rangé dans la table `concept`. Pour afficher le libellé, il faut donc « relier » les deux tables : c'est une jointure.

La jointure s'appuie sur les clés : la clé étrangère `condition_concept_id` de condition_occurrence pointe vers la clé primaire `concept_id` de concept. On écrit cette correspondance après le mot `ON`.

Pour écrire moins, on donne un surnom (alias) à chaque table : `condition_occurrence co`, `concept c`. On précise alors de quelle table vient chaque colonne : `co.person_id`, `c.concept_name`.

Exemple commenté

```
SELECT co.person_id, co.condition_start_date, c.concept_name
FROM condition_occurrence co
JOIN concept c ON c.concept_id = co.condition_concept_id
LIMIT 3;
```

Ligne de la requête	Ce qu'elle veut dire
`SELECT co.person_id, co.condition_start_date, c.concept_name`	deux colonnes viennent de condition_occurrence (co), le libellé vient de concept (c) ;
`FROM condition_occurrence co`	je pars de la table des diagnostics, surnommée co ;
`JOIN concept c ON c.concept_id = co.condition_concept_id`	pour chaque diagnostic, je vais chercher dans concept la ligne dont le concept_id est égal au code du diagnostic ;
`LIMIT 3;`	j'affiche 3 lignes.

Résultat obtenu :

person_id	condition_start_date	concept_name
263	2015-10-02	Acute viral pharyngitis
273	2011-10-10	Gastrointestinal hemorrhage
283	1984-02-15	Streptococcal sore throat

3 lignes.

Exercices

Exercice 3.1 — Première jointure

Affichez l'identifiant, l'année de naissance et le libellé du genre (tel qu'il est écrit dans la table `concept`) de 10 patients.

Exercice 3.2 — Les diagnostics les plus fréquents

Quels sont les 10 diagnostics les plus fréquents ? Affichez leur libellé et leur nombre d'occurrences.

Exercice 3.3 — Les médicaments les plus prescrits

Même question pour les médicaments : les 10 plus fréquents dans la table `drug_exposure`.

Exercice 3.4 — Le dossier d'un patient

Affichez la liste des diagnostics du patient n° 6 : la date de début et le libellé de chaque diagnostic, du plus ancien au plus récent.

Exercice 3.5 — Lignes ou patients ?

Combien y a-t-il de diagnostics « Gastrointestinal hemorrhage » (concept_id `192671`) dans la base ? Combien de patients différents sont concernés ? Faites les deux calculs dans une seule requête.

Niveau 4 — Questions cliniques

Durée conseillée : 40 min **Notions :** Plusieurs jointures, IN, calculs sur les dates

Mini-cours

Cette base d'exemple a été construite autour d'une question de pharmaco-épidémiologie : le risque d'hémorragie digestive (gastrointestinal hemorrhage, concept_id `192671`) chez des patients traités par deux anti-inflammatoires, le célécoxib (concept_id `1118084`) et le diclofénac (concept_id `1124300`).

Les dates sont stockées sous la forme `AAAA-MM-JJ` (par exemple `2011-10-10`). Ce format permet de les comparer directement : `'2010-05-01' < '2011-10-10'` est vrai. Pour extraire l'année d'une date, on utilise `strftime('%Y', une_date)`.

Pour tester si une valeur appartient à une liste, on écrit `IN (valeur1, valeur2)`.

Exemple commenté

```
SELECT condition_start_date,
       strftime('%Y', condition_start_date) AS annee
FROM condition_occurrence
LIMIT 3;
```

Ligne de la requête	Ce qu'elle veut dire
`SELECT condition_start_date,`	la date complète du diagnostic ;
`strftime('%Y', condition_start_date) AS annee`	seulement l'année de cette date, dans une colonne nommée annee ;
`FROM condition_occurrence LIMIT 3;`	3 lignes de la table des diagnostics.

Résultat obtenu :

condition_start_date	annee
2015-10-02	2015
2011-10-10	2011
1984-02-15	1984

3 lignes.

Exercices

Exercice 4.1 — Âge au moment de l'hémorragie

Pour les patients ayant eu une hémorragie digestive (concept_id `192671`), calculez l'âge moyen (arrondi à une décimale), l'âge minimum et l'âge maximum au moment du diagnostic. On prendra un âge approximatif : année du diagnostic moins année de naissance.

Exercice 4.2 — Répartition par genre

Parmi les patients ayant eu une hémorragie digestive, combien sont des hommes et combien sont des femmes ? Affichez le libellé du genre tel qu'il figure dans la table `concept`.

Exercice 4.3 — Exposition aux anti-inflammatoires

Combien de patients ayant eu une hémorragie digestive ont reçu, à un moment quelconque, du célécoxib (drug_concept_id `1118084`) ou du diclofénac (drug_concept_id `1124300`) ? Le résultat vous paraît-il plausible ?

Exercice 4.4 — Exposition avant l'événement

Reprenez la question précédente en ne retenant que les prescriptions qui ont commencé AVANT le diagnostic d'hémorragie. Détaillez le résultat par médicament (libellé).

Niveau 5 — Bonus : pour aller plus loin

Durée conseillée : facultatif **Notions :** Double jointure, calculs de durée, hiérarchie des concepts, WITH, CASE, LEFT JOIN

> **Mini-cours**
>
> Ces exercices sont facultatifs, pour celles et ceux qui ont terminé. Ils reprennent des techniques utilisées dans les vraies études sur entrepôts de données de santé.

Exercices

Exercice 5.1 — Patients par décennie de naissance

Comptez le nombre de patients par décennie de naissance (1900, 1910, 1920…), dans l'ordre chronologique.

Exercice 5.2 — Code source et code standard

Chaque diagnostic a deux codes : `condition_concept_id` (code standard, vocabulaire SNOMED) et `condition_source_concept_id` (code d'origine, par exemple CIM-10). Pour les diagnostics dont le libellé standard contient « hemorrhage », affichez le libellé standard, son vocabulaire, le libellé source, son vocabulaire, et le nombre d'occurrences.

Exercice 5.3 — Durée de suivi

La table `observation_period` indique, pour chaque patient, la période pendant laquelle il est suivi dans la base (`observation_period_start_date` et `observation_period_end_date`). Calculez la durée moyenne de suivi en années, arrondie à une décimale.

Exercice 5.4 — Utiliser la hiérarchie des concepts

La table `concept_ancestor` relie chaque concept à ses « ancêtres ». Par exemple, la substance Ibuprofen (concept_id `1177480`) est l'ancêtre des produits « Ibuprofen 200 MG Oral Tablet », etc. Comptez le nombre de prescriptions de chaque produit contenant de l'ibuprofène, sans écrire leurs codes un par un.

Exercice 5.5 — Comparer exposés et non exposés

Classez les patients en deux groupes : ceux qui ont reçu au moins une fois du célécoxib (`1118084`) et les autres. Pour chaque groupe, donnez le nombre de patients, le nombre de patients ayant eu une hémorragie digestive, et le pourcentage correspondant.